MemImpact 执行计划评审意见

Nov 11, 2026 · @GOAT

本文是对《MemImpact 组会与执行计划》的评审，并附上相关文献调研的结论，供明天组会讨论。结论先说：**计划整体合理，但测试矩阵有一个设计问题，会直接影响核心结论，建议开会时先定下来。**

1. 总体评价

做得好的地方：

- 研究问题已收窄为「重新运行 Planner 相对固定候选动作审计的增量价值」，关键对照（MemImpact vs AMV-Guard-style）选对了。
- 防泄漏（隐藏标签不进 prompt、同一基础场景的变体放同一 split）、成本口径（含反事实审计和 replan）、结果为负也算完成，这些都已写进计划。
- 时间表顺序合理，「最后三天不加新算法」「先砍扩展不砍基线」的取舍正确。

2. 文献背景：为什么要把对照做扎实

「反事实记忆评分」和「按影响分配验证预算」在最近几个月已有多篇工作，不能再单独当作创新点：

工作	做了什么	与我们的关系
CMI（arXiv 2605.17641）	按记忆对当前回答的因果效应选择记忆	反事实影响评分
MeClear（arXiv 2609.09115）	留一法加采样 Shapley 归因，屏蔽有害记忆	反事实审计，且证明了留一法对冗余记忆的盲区
ConMem（arXiv 2610.33432）	用反事实处理效应决定记忆是否保留，分离生成随机性	噪声处理思路可借鉴
AMV-Guard（arXiv 2610.31446）	给定候选动作，用信息价值（VOI）决定验证哪些记忆前提	就是我们的 AMV-style 基线，也是最直接的对手
SEDM（arXiv 2609.09498）	用有/无记忆的结果监督一个门控，成本入决策	整组粒度的摊销门控

现有工作留下的缺口，也就是我们真正能贡献的点：AMV-Guard 的前提来自抽取器和工具契约，其反事实翻转只用于评测标签，不重新运行规划器。因此它能抓住「地址是 X」这类硬前提，但抓不住影响了「选哪个动作」的软记忆。MemImpact 的逐条移除加重规划正好测这一点。

另有一条对设计有用的结论：Manufactured Confidence（arXiv 2606.29279）发现被动的「未验证」标签会被模型忽略，所以「根据来源标签决策」不能只靠提示词。

3. 最大的问题：测试矩阵可能区分不了两种方法

现在的五类记忆条件（Valid / Stale / Conflicting / Misattributed / Irrelevant）变化的是记忆对不对，没有变化记忆怎么影响动作。

在 messaging 这类任务里，关键记忆（如电话号码）直接出现在工具参数里。这种硬前提靠前提抽取就能找到，不需要重新规划。结果是 MemImpact 和 AMV-style 很可能选中同一条记忆验证，最终结果相同，而 MemImpact 多花至少 12 次 Planner 调用。第 7.1 节「最关键的对照」会得到由数据设计决定的平局。

重新规划真正可能占优的情形，是记忆不出现在参数里、却改变了选哪个动作，例如「工作日联系他要发工作号」「上次说的 Sam 指 Sam Lee」。

建议修改：增加「依赖类型」因子（直接进参数 / 间接影响动作选择），场景变体从 6 减到 3，总数不变：

2 任务族 × 5 记忆条件 × 2 后果等级 × 2 依赖类型 × 3 变体 = 120 episodes

这样无论哪边赢，结果都有解释力。

4. 其他需要在会上确定的点

1. **F_i 没有扣除噪声。** 目前 Planner 自身的随机波动会被算作翻转。已有的 3 次完整规划两两比较即可得到基线翻转率 F_0，不需要额外调用，直接用 F_i − F_0。同时要确定温度：温度为 0 时 S=3 基本是重复调用，可降到 S=1 省钱。
2. **冗余记忆是留一法的盲区。** 两条记忆指向同一个旧号码时，移除任意一条动作都不变，两条的 F 都是 0，MemImpact 会放行有害动作。3 条记忆的规模下，加一个「全部移除」分支只多 3 次调用。至少在测试集里放几个这样的场景，并作为已知局限报告。
3. **AMV-style 基线要防止变成稻草人。** 它应拿到和 MemImpact 相同的不确定性特征和排序公式，只把 F_i 换成前提抽取结果；实现在看到测试结果前冻结。另外「可比预算」目前只指验证次数，Planner 调用成本没有对齐，可靠性—成本图的横轴应使用总成本。
4. **5.4 的关键记忆标签没有负责人。** 离线「验证—重规划」试验是一块独立工作量，A–E 都没认领，建议分给 B 或 E。

5. 较小的建议

- **缓存反事实输出。** 同一 episode 的完整规划和移除规划结果，MemImpact、action-flip-only 和两档验证预算可共用；所有策略从同一个初始候选动作出发。既省钱，也消除变体间的随机差异。

- **可调参数控制在两个以内。** 开发集只有 40 个 episode，且任务族与测试集不同，λ 和阈值多了容易过拟合。
- **预先指定一个主比较。** 每个格子只有 3–6 个样本，分条件的置信区间会很宽，只做描述性分析。
- **给 ToolSandbox 集成设截止点。** 11/12–11/16 是全计划风险最高的一段。建议定 11/14 为判断日，并现在就写明接不通时的备选方案。

6. 明天会上建议先定的事项

- [ ] 是否采用「依赖类型」因子并调整测试矩阵（第 3 节）。
- [ ] F_i 是否扣除基线翻转率，以及温度和 S 的取值。
- [ ] 是否加入「全部移除」分支和冗余记忆场景。
- [ ] AMV-style 基线的特征对齐和冻结时间。
- [ ] 关键记忆标签的负责人。
- [ ] ToolSandbox 集成的判断日（11/14）和备选方案。

7. 说明与局限

- 文献部分基于检索到的摘要和论文页面。AMV-Guard 只读到了主实验表之前的部分，其失败分析和局限性一节没有读到。
- 各基准（ToolSandbox、STALE、MemSyco-Bench）的代码是否公开、能否与 LangGraph 共环境，需要 A 在 smoke test 中核实。
- 这些是评审建议，不是定论，请以组内讨论为准。